

**PREDIKSI TREN FREKUENSI, SEVERITAS, DAN NOMINAL KLAIM
ASURANSI KESEHATAN INDIVIDU MENGGUNAKAN
PENDEKATAN ENSEMBLE MACHINE LEARNING UNTUK
OPTIMASI MANAJEMEN RISIKO**



FANTASTIC THREE

- 1. Rizki Pangestu**
- 2. Hanif Rifan Ash Shidiq**
- 3. Hatta Pramana Syahputra**

**DATA SCIENCE COMPETITION
MATHEMATICAL CHALLENGE FESTIVAL
INSTITUT TEKNOLOGI BANDUNG**

2026

LEMBAR PERNYATAAN ORSINALITAS DAN DEKLARASI PENGUNAAN KECERDASAN BUATAN GENERATIF

Kami yang bertanda tangan di bawah ini:

Nama Tim : Fantastic Three
Nama Ketua Tim : Rizki Pangestu
Nama Anggota Tim 1 : Hanif Rifan Ash Shidiq
Nama Anggota Tim 2 : Hatta Pramana Syahputra

Dengan ini menyatakan bahwa laporan yang kami sertakan dalam perlombaan Data Science Competition MCF ITB 2026 merupakan hasil karya orisinal, tidak mengandung plagiarisme dari pihak manapun, dan belum pernah diikutsertakan dalam perlombaan lain.

Kami juga mendeklarasikan penggunaan kecerdasan buatan generatif (Generative AI) dalam proses penyusunan laporan ini. Model kecerdasan buatan generatif yang digunakan adalah sebagai berikut:

Nama Model : Claude Sonnet dan Claude Opus
Pengembang Model : Anthropic

Kami menggunakan model kecerdasan buatan generatif tersebut untuk keperluan berikut:

Pembuatan kode (code generation) — Claude Sonnet dan Claude Opus digunakan untuk membantu menulis, memperbaiki, dan mengoptimalkan kode dalam proses analisis data. Seluruh kode yang dihasilkan telah ditinjau, diverifikasi, dan disesuaikan oleh tim.

Kami menyatakan bahwa seluruh keluaran model kecerdasan buatan generatif yang digunakan telah melalui proses peninjauan, verifikasi, dan pengolahan ulang oleh tim. Seluruh isi laporan yang dikumpulkan merupakan hasil pemahaman, analisis, dan tanggung jawab kami sebagai peserta kompetisi.

Apabila di kemudian hari kami diketahui melanggar pernyataan ini, kami siap menerima konsekuensi yang telah ditetapkan oleh panitia MCF ITB 2026 berupa sanksi diskualifikasi dari perlombaan ini. Demikian pernyataan ini dibuat dengan sebenarnya, untuk digunakan sebagaimana mestinya.

Yogyakarta, 15 Maret

Yang menyatakan,

Rizki Pangestu

ABSTRAK

Peningkatan klaim asuransi kesehatan individu sebesar 25,5% pada Januari–Juni 2025 mendorong kebutuhan model prediktif yang akurat untuk mendukung manajemen risiko perusahaan asuransi. Penelitian ini membangun model prediksi tren frekuensi, severitas, dan total nominal klaim asuransi kesehatan individu menggunakan pendekatan ensemble machine learning berbasis enam model, yaitu Prophet, LightGBM, XGBoost, Ridge Regression, ElasticNet, dan Exponential Smoothing (ETS/Holt-Winters), dengan optimasi bobot menggunakan algoritma SLSQP (Sequential Least-Squares Programming). Data yang digunakan mencakup 5.781 catatan klaim dan 4.096 polis aktif pada periode Januari 2024 hingga Juli 2025. Proses feature engineering menghasilkan 28 fitur yang meliputi cyclical encoding kalender, lag features, rolling statistics, transformasi logaritma, dan severity skewness ratio. Validasi model dilakukan menggunakan metode walk-forward cross-validation untuk menghindari data leakage. Hasil evaluasi menunjukkan bahwa LightGBM unggul untuk prediksi frekuensi (MAPE 6,32%), ElasticNet unggul untuk prediksi severitas (MAPE 5,40%), dan XGBoost unggul untuk prediksi total nominal klaim (MAPE 7,32%). Model ensemble akhir dengan severity multiplier 0,960 mencapai MAPE gabungan terbaik sebesar 4,40%. Proyeksi untuk Januari–Desember 2026 menunjukkan frekuensi klaim yang meningkat bertahap dengan puncak pada Q3–Q4 (238–239 klaim/bulan), severitas yang relatif stabil pada kisaran Rp45–47 juta per klaim, dan total nominal klaim berkisar antara Rp10,9–11,2 miliar per bulan. Berdasarkan hasil proyeksi, direkomendasikan penguatan cadangan teknis pada semester kedua, pengendalian klaim rawat inap dan luar negeri, program preventif untuk menekan frekuensi klaim, serta implementasi sistem early warning berbasis realisasi klaim bulanan.

DAFTAR GAMBAR

Gambar 3.1 Output Missing Values dan Statistik Deskriptif Nominal Klaim	
Gambar 3.2 Box Plot: Nominal Klaim, Usia Pasien, dan LOS	
Gambar 3.3 Histogram: Distribusi Nominal Klaim, Usia Pasien, dan LOS.....	
Gambar 3.4 Correlation Heatmap: Fitur vs Nominal Klaim	
Gambar 3.5 Box Plot: Inpatient/Outpatient	
Gambar 3.6 Scatter Plot	
Gambar 3.7 Time Series: Frekuensi, Severitas, dan Total Nominal Klaim.....	
Gambar 3.8 Multi-Metrik Model	
Gambar 3.9 Visualisasi MAPE.....	
Gambar 3.10.....Feature Importance: Frekuensi, Severitas, dan Total Klaim (Top 15)	
Gambar 3.11.....Feature Importance: Frekuensi, Severitas, dan Total Klaim (Top 5)	
Gambar 3.12.....Perbandingan Dengan Dan Tanpa Feature Enggining	
Gambar 3.13.....Proyeksi Frekuensi, Severitas, dan Total Nominal Klaim Jan–Des 2026	
Gambar 3.14 Visualisasi Proyeksi: Frekuensi, Severitas, dan Total Klaim 2026	

DAFTAR ISI

ABSTRAK	3
DAFTAR GAMBAR.....	4
DAFTAR ISI	4
BAB 1.....	6
PENDAHULUAN	6
1.1 Latar Belakang	6
1.2 Rumusan Masalah	7
1.3 Tujuan.....	8
BAB 2.....	9
METODOLOGI	9
2.1 Model	9
2.1 Feature Engineering.....	11
BAB 3.....	13
HASIL DAN PEMBAHASAN	13
3.1 Exploratory Data Analysis (EDA).....	13
3.1.1.Deskripsi Dataset	13
3.1.2. Identifikasi Missing Values dan Data Duplikat	13

3.1.3. Deteksi dan Penanganan Outlier	14
3.1.4. Analisis Distribusi.....	14
3.1.5. Analisis Korelasi	15
3.1.6. Analisis Box Plot Berdasarkan Segmen.....	15
3.1.7. Analisis Scatter Plot	15
3.1.8. Analisis Time Series Bulanan	16
3.2 Machine Learning Training.....	17
3.2.1. Feature Engineering	17
3.2.2. Model.....	18
3.2.3. Pencarian Konfigurasi Terbaik (Hyperparameter Search)	19
3.2.4. Cross-Validation Walk-Forward	20
3.2.5. Optimasi Bobot Ensemble (SLSQP).....	20
3.2.6. Evaluasi Multi-Metrik Model	20
3.2.7. Identifikasi Faktor Paling Berpengaruh.....	21
3.2.8. Perbandingan Dengan dan Tanpa Feature Engineering	23
3.3 Hasil Prediksi	23
3.3.1 Kalibrasi Model (Severity Multiplier).....	23
3.3.1 Proyeksi Klaim Tahun 2026	24
3.3.1 Analisis Tren Proyeksi 2026	25
3.3.1 Rekomendasi Strategis	25
BAB 4.....	26
PENUTUP.....	26
4.1 Kesimpulan Dan Saran	26
4.1 Daftar Pustaka.....	27

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Pada saat ini peningkatan klaim asuransi kesehatan individu menjadi salah satu isu yang cukup serius di industri asuransi. Data menunjukkan bahwa terjadi kenaikan klaim sebesar 25,5% pada periode Januari hingga Juni 2025 jika dibandingkan periode yang sama di tahun 2024. Kondisi ini berdampak langsung pada penyesuaian premi yang berpotensi membuat harga premi produk asuransi kesehatan individu menjadi semakin tidak terjangkau bagi masyarakat. Produk asuransi kesehatan individu sendiri merupakan salah satu alat mitigasi risiko finansial individu dari kejadian tidak terduga seperti penyakit atau kecelakaan yang berpotensi menimbulkan biaya besar dan berdampak pada perencanaan keuangan pribadi [1].

Berdasarkan penelitian sebelumnya, analisis prediktif berbasis *machine learning* telah banyak digunakan dalam industri asuransi untuk mengelola risiko klaim secara lebih efisien. Hermawan et al. (2025) membuktikan bahwa model *machine learning* seperti *Logistic Regression*, *Random Forest*, dan *XGBoost* mampu menekan potensi kerugian finansial akibat kesalahan prediksi klaim hingga tiga kali lebih rendah dibandingkan metode berbasis aturan konvensional [2]. Penelitian lain menunjukkan bahwa penggunaan kecerdasan buatan dan *machine learning* dalam ilmu aktuaria secara signifikan mengubah cara perusahaan asuransi dalam melakukan penilaian risiko, otomatisasi proses klaim, hingga deteksi dini potensi kecurangan [3]. Namun demikian, penelitian yang secara spesifik mengintegrasikan prediksi tren frekuensi klaim, severitas klaim, dan nominal total klaim asuransi kesehatan individu secara bersamaan masih sangat terbatas.

Permasalahan utama yang dihadapi adalah bagaimana membangun model prediktif yang mampu memprediksi ketiga dimensi klaim tersebut secara akurat, sehingga perusahaan asuransi dapat melakukan inisiatif baik dari segi seleksi risiko, pencegahan, maupun deteksi dini untuk meminimalisir dampak peningkatan klaim guna menjaga harga premi yang tetap terjangkau [4].

Untuk menyelesaikan permasalahan tersebut, penelitian ini ditujukan untuk membangun model prediktif berbasis *ensemble machine learning* yang menggabungkan enam model sekaligus, yaitu Prophet, LightGBM, XGBoost, Ridge Regression, ElasticNet, dan *Exponential Smoothing* (ETS/Holt-Winters), dengan optimasi bobot menggunakan metode SLSQP (*Sequential Least Squares Programming*). Model ini diharapkan mampu memprediksi tren frekuensi, severitas, dan nominal klaim asuransi kesehatan individu untuk periode Januari hingga Desember 2026, serta memberikan rekomendasi strategis berbasis data kepada perusahaan asuransi dalam menjaga keterjangkauan premi.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan di atas, terdapat beberapa permasalahan yang menjadi fokus dalam penelitian ini, yaitu:

1. Bagaimana karakteristik dan pola data klaim asuransi kesehatan individu, serta faktor-faktor apa saja yang berpotensi menjadi *outlier* atau memiliki ketidaklengkapan data yang dapat memengaruhi performa model prediktif?
2. Faktor-faktor apa yang paling berpengaruh terhadap severitas klaim asuransi kesehatan individu?
3. Faktor-faktor apa yang paling berpengaruh terhadap frekuensi klaim asuransi kesehatan individu?
4. Dari keenam model yang diuji dalam penelitian ini, yaitu Prophet, LightGBM, XGBoost, Ridge Regression, ElasticNet, dan *Exponential Smoothing* (ETS/Holt-Winters), model mana yang memberikan performa terbaik, dan bagaimana pendekatan *ensemble* berbasis optimasi bobot SLSQP dapat meningkatkan akurasi prediksi untuk tren frekuensi klaim, tren severitas klaim, tren nominal total klaim untuk periode Januari hingga Desember 2026?
5. Bagaimana perbandingan performa model prediksi klaim asuransi kesehatan individu dengan dan tanpa penerapan *feature engineering*?
6. Apa rekomendasi strategis yang dapat diberikan kepada perusahaan asuransi berdasarkan hasil prediksi tren frekuensi, severitas, dan nominal klaim untuk periode Januari hingga Desember 2026, guna menjaga keterjangkauan premi asuransi kesehatan individu?

1.3 Tujuan

Berdasarkan rumusan masalah yang telah diuraikan di atas, penelitian ini memiliki beberapa tujuan yang ingin dicapai, yaitu:

1. Melakukan eksplorasi dan pembersihan data klaim asuransi kesehatan individu, termasuk mengidentifikasi data yang tidak lengkap, duplikasi, serta *outlier* yang berpotensi memengaruhi performa model prediktif yang akan dibangun.
2. Mengidentifikasi faktor-faktor yang paling berpengaruh terhadap severitas klaim asuransi kesehatan individu berdasarkan analisis *feature importance* dari model *machine learning* yang digunakan.
3. Mengidentifikasi faktor-faktor yang paling berpengaruh terhadap frekuensi klaim asuransi kesehatan individu berdasarkan analisis *feature importance* dari model *machine learning* yang digunakan.
4. Membangun dan membandingkan performa minimal enam model *machine learning*, yaitu Prophet, LightGBM, XGBoost, Ridge Regression, ElasticNet, dan *Exponential Smoothing* (ETS/Holt-Winters), dalam memprediksi tren frekuensi klaim, tren severitas klaim, tren nominal total klaim untuk periode Januari hingga Desember 2026. Memberikan rekomendasi strategis kepada perusahaan asuransi berdasarkan hasil prediksi tren frekuensi, severitas, dan nominal klaim untuk periode Januari hingga Desember 2026, guna mendukung pengambilan keputusan dalam hal seleksi risiko, penetapan premi, dan kebijakan pencegahan klaim yang dapat menjaga keterjangkauan premi asuransi kesehatan individu.
5. Mengevaluasi dan membandingkan performa model prediksi klaim asuransi kesehatan individu dengan dan tanpa penerapan *feature engineering*, guna mengukur sejauh mana *feature engineering* berkontribusi terhadap peningkatan akurasi model.
6. Membangun model *ensemble* berbasis optimasi bobot SLSQP (*Sequential Least Squares Programming*) yang menggabungkan prediksi dari keenam model *machine learning* secara simultan, sehingga menghasilkan prediksi akhir yang lebih *robust* dan akurat dibandingkan model tunggal.

BAB 2

METODOLOGI

2.1 Model

Pipeline pada penelitian ini menggunakan *ensemble* 6 model dengan bobot yang dioptimasi secara terpisah untuk frekuensi, severitas, dan total klaim. Berikut adalah penjelasan dari masing-masing model yang digunakan.

a. Prophet (Facebook/Meta)

Prophet merupakan model deret waktu yang bekerja dengan cara mendekomposisi data menjadi tiga komponen utama, yaitu tren pertumbuhan jangka panjang (piecewise linear), pola musiman tahunan (Fourier series), dan perubahan mendadak (changepoints) yang dideteksi secara otomatis. Parameter `changepoint_prior_scale=0.01` dikecilkan agar model tidak overfit terhadap fluktuasi jangka pendek. Mode `multiplicative` dipilih karena amplitudo musiman mengikuti skala tren, yang lazim terjadi pada data keuangan. Keunggulan model ini adalah robust terhadap missing data dan outlier serta dapat menangani musiman secara otomatis. Namun demikian, model ini tidak memanfaatkan fitur eksogen.

b. LightGBM (Light Gradient Boosting Machine)

LightGBM bekerja dengan cara membangun pohon keputusan secara bertahap (boosting), di mana setiap pohon baru memperbaiki kesalahan pohon sebelumnya. Model ini menggunakan teknik GOSS (Gradient-based One-Side Sampling) untuk efisiensi pada dataset kecil. Konfigurasi kunci yang digunakan adalah `objective='poisson'` untuk prediksi frekuensi karena distribusi Poisson cocok untuk count data, serta `objective='mape'` untuk prediksi severitas. Parameter `num_leaves=3–6` dan `n_estimators=80–150` digunakan sebagai regularisasi yang kuat untuk mencegah overfit pada data bulanan yang jumlahnya terbatas.

c. XGBoost (Extreme Gradient Boosting)

XGBoost memiliki cara kerja yang serupa dengan LightGBM, namun menggunakan pendekatan `level-wise tree growth` yang lebih konservatif dibandingkan LightGBM yang bersifat `leaf-wise`. Model ini cenderung lebih lambat namun seringkali lebih stabil pada dataset kecil. Konfigurasi yang digunakan adalah `objective='count:poisson'` untuk prediksi frekuensi dan `objective='reg:absoluteerror'` untuk prediksi severitas. Parameter `max_depth=2–4`

dan subsample=0.6 digunakan untuk menghasilkan pohon yang sangat dangkal guna mencegah overfit.

d. Ridge Regression

Ridge Regression merupakan regresi linear dengan penalti L2 yang diformulasikan sebagai berikut:

$$Loss = \sum (y - \hat{y})^2 + \alpha \times \sum (\beta^2)$$

Koefisien yang terlalu besar akan "dihukum" sehingga model menjadi lebih stabil saat fitur-fitur berkorelasi tinggi. Sebelum proses fitting, seluruh fitur dinormalisasi menggunakan StandardScaler (mean=0, std=1) karena Ridge Regression sensitif terhadap skala fitur.

e. ElasticNet

ElasticNet merupakan kombinasi dari penalti L1 (Lasso) dan L2 (Ridge) yang diformulasikan sebagai berikut:

$$Loss = \sum (y - \hat{y})^2 + \alpha \times 1_ratio \times \sum |\beta| + \alpha \times (1 - 1_ratio) \times \sum (\beta^2)$$

Penalti L1 mendorong beberapa koefisien menjadi tepat nol sehingga berfungsi sebagai feature selection otomatis, sedangkan penalti L2 menstabilkan koefisien yang tersisa. Model ini sangat cocok digunakan ketika terdapat banyak fitur namun tidak semuanya relevan terhadap variabel target.

f. ETS — Exponential Smoothing (Holt-Winters)

ETS bekerja dengan cara memberikan bobot eksponensial yang semakin kecil untuk data yang semakin lama, sehingga data terbaru mendapatkan bobot lebih besar. Model ini menggunakan tiga komponen utama yaitu level, tren, dan musiman yang dirumuskan sebagai berikut:

- *Level*: $L_t = \alpha \times Y_t + (1 - \alpha) \times (L_{t-1} + T_{t-1})$
- *Tren*: $T_t = \beta \times (L_t - L_{t-1}) + (1 - \beta) \times T_{t-1}$
- *Musiman*: $S_t = \gamma \times (Y_t - L_t) + (1 - \gamma) \times S_{t-12}$

Parameter `damped_trend=True` digunakan agar tren jangka panjang tidak meningkat secara tidak realistis. Model ini murni berbasis historis deret waktu dan tidak menggunakan fitur eksogen.

g. Ensemble dan Optimasi Bobot

Keenam model digabungkan menggunakan pendekatan ensemble dengan bobot optimal yang dicari menggunakan algoritma SLSQP (Sequential Least-

Squares Programming). Proses optimasi dilakukan dengan meminimalkan nilai MAPE gabungan sebagai berikut:

- Minimasi: $MAPE_{gabungan} = (MAPE_{frekuensi} + MAPE_{seviritas} + MAPE_{total})/3$
- Subjek ke: $w_1 + w_2 + \dots + w_n = 1$
 $0 \leq w_i \leq 0.6$

Batasan bobot maksimum sebesar 0,6 diterapkan agar tidak ada satu model yang mendominasi prediksi akhir lebih dari 60%. Total nominal klaim dihitung sebagai kombinasi antara prediksi implisit dan prediksi langsung sebagai berikut:

- $Total_Claim = \alpha (frekuensi \times seviritas) + (1 - \alpha) \times Prediksi_Direct$

Nilai α juga dioptimasi dalam proses yang sama, sehingga kombinasi antara prediksi implisit dan prediksi langsung total klaim dapat menghasilkan akurasi yang paling optimal.

h. Cross-Validation (Walk-Forward)

Untuk menghindari data leakage pada data deret waktu, penelitian ini menggunakan metode walk-forward validation sebagai berikut:

- Iterasi 1: Training : bulan 1–12 | Test : bulan 13
- Iterasi 2: Training : bulan 1–13 | Test : bulan 14
- Iterasi n: Training : bulan 1–(n–1) | Test : bulan n

Pada setiap iterasi, model dilatih ulang dari awal tanpa ada data masa depan yang "bocor" ke dalam proses training. Pendekatan ini merepresentasikan kondisi prediksi nyata di mana model hanya mengetahui data historis yang telah tersedia pada saat prediksi dilakukan.

2.1 Feature Engineering

Feature engineering adalah proses menciptakan variabel baru dari data mentah agar model dapat menangkap pola yang lebih kompleks. Pada penelitian ini digunakan 5 jenis transformasi sebagai berikut.

a. Fitur Kalender (Cyclical Encoding)

Fitur kalender dibuat menggunakan transformasi sinus-kosinus untuk merepresentasikan sifat siklus dari data bulanan:

- $Month_Sin = \sin (2\pi \times Bulan/12)$
- $Month_Cos = \cos (2\pi \times Bulan/12)$

Bulan bersifat siklus, di mana setelah Desember akan kembali ke Januari, sehingga encoder linier biasa tidak tepat untuk merepresentasikan hubungan tersebut. Transformasi sinus-kosinus mengubah bulan menjadi koordinat lingkaran sehingga jarak antara Desember dan Januari menjadi kecil, bukan besar. Selain itu, variabel Quarter dan Time_Index juga ditambahkan untuk menangkap tren linear jangka panjang.

b. Lag Features (Fitur Keterlambatan)

Lag features dibuat untuk memungkinkan model "mengingat" kondisi masa lalu, yang sangat relevan untuk data deret waktu karena klaim bulan ini cenderung berkorelasi dengan klaim bulan sebelumnya (autocorrelation). Fitur ini diterapkan pada variabel Frequency, Avg_Severity, dan Total_Claim sebagai berikut:

- Frequency_Lag1= nilai frekuensi bulan lalu ($t-1$)
- Frequency_Lag2= nilai frekuensi 2 bulan lalu ($t-2$)
- Frequency_Lag3= nilai frekuensi 3 bulan lalu ($t-3$)

c. Rolling Statistics (Statistik Bergulir)

Rolling statistics digunakan untuk menangkap pola jangka pendek dari data historis. Proses ini menggunakan shift(1) sebelum rolling untuk menghindari data leakage, di mana nilai bulan saat ini tidak ikut dihitung dalam kalkulasi. Fitur yang dibuat adalah sebagai berikut:

- Frequency_RollMean3 = rata-rata frekuensi 3 bulan terakhir
- Frequency_RollMedian3= median frekuensi 3 bulan terakhir
- Frequency_RollStd3= standar deviasi frekuensi 3 bulan terakhir

Standar deviasi digunakan untuk menangkap volatilitas klaim, di mana bulan dengan volatilitas tinggi cenderung memiliki risiko yang lebih besar.

d. Transformasi Logaritma

Transformasi logaritma diterapkan pada variabel severitas klaim karena distribusinya sangat *right-skewed* (ekor kanan panjang):

- $\text{Log_Severity} = \log(1 + \text{Avg_Severity})$

Transformasi ini berfungsi untuk menekan *outlier* ekstrem dan membuat distribusi lebih mendekati normal, sehingga model linear seperti Ridge Regression dan ElasticNet dapat bekerja lebih optimal.

e. Severity Skewness Ratio

Severity Skewness Ratio merupakan rasio yang mengukur seberapa asimetris distribusi klaim dalam satu bulan:

- $\text{Severity_Skew} = \text{Median_Severity} / \text{Avg_Severity}$

Nilai mendekati 1 berarti distribusi simetris, sedangkan nilai yang jauh di bawah 1 menandakan adanya klaim ekstrem yang mendorong rata-rata jauh di atas median. Kondisi ini menjadi sinyal bahwa bulan tersebut memiliki risiko klaim yang tinggi.

BAB 3

HASIL DAN PEMBAHASAN

3.1 Exploratory Data Analysis (EDA)

3.1.1.Deskripsi Dataset

Penelitian ini menggunakan dua sumber data utama, yaitu `Data_Klaim.csv` dan `Data_Polis.csv`. Data klaim berisi 5.781 catatan transaksi klaim asuransi kesehatan individu yang terjadi pada periode 1 Januari 2024 hingga 31 Juli 2025, sedangkan data polis berisi informasi dari 4.096 polis aktif.

`Data_Klaim.csv` terdiri dari 13 kolom yang mencakup identitas klaim, metode penyelesaian (reimburse/cashless), kategori perawatan (rawat inap/rawat jalan), kode diagnosis ICD, status klaim (*Paid/Pending*), tanggal masuk dan keluar rumah sakit, nominal klaim yang disetujui, serta lokasi rumah sakit. Dalam analisis ini, hanya klaim berstatus *Paid* yang digunakan, sedangkan klaim berstatus *Pending* dieksklusi karena nominalnya belum bersifat final.

`Data_Polis.csv` terdiri dari 6 kolom yang mencakup nomor polis, *plan code*, gender, tanggal lahir, tanggal efektif polis, dan domisili. Variabel *plan code* merepresentasikan cakupan wilayah pertanggunganaan, yaitu M-001 untuk seluruh dunia, M-002 untuk regional Asia, dan M-003 untuk domestik Indonesia.

3.1.2. Identifikasi Missing Values dan Data Duplikat

Hasil pemeriksaan kelengkapan data pada `Data_Klaim.csv` menunjukkan adanya missing values pada beberapa kolom, yaitu kolom Inpatient/Outpatient dan Tanggal Pembayaran Klaim masing-masing sebanyak 37 baris, Lokasi RS sebanyak 7 baris, serta ICD Diagnosis dan ICD Description masing-masing sebanyak 6 baris. Nilai kosong tersebut ditangani dengan pengisian menggunakan nilai modus atau kategori "Tidak Diketahui" agar observasi tetap dapat dipertahankan. Tidak ditemukan baris duplikat pada kedua dataset (duplikat = 0). Hasil pemeriksaan missing values dan statistik deskriptif nominal klaim dapat dilihat pada gambar berikut.

```
=== Missing Values - Data Klaim ===
Inpatient/Outpatient      37
ICD Diagnosis             6
ICD Description           6
Tanggal Pembayaran Klaim  37
Lokasi RS                 7

Duplikat baris klaim : 0
Duplikat baris polis : 0


Statistik Nominal Klaim Yang Disetujui:
count      4,627
mean    48,521,361
std      87,103,182
min           0
25%    2,274,009
50%    14,467,099
75%    51,072,005
max    446,068,114
Name: Nominal Klaim Yang Disetujui, dtype: object
```

Gambar 3.1 Output Missing Values dan Statistik Deskriptif Nominal Klaim Berdasarkan statistik deskriptif yang dihasilkan, distribusi nominal klaim bersifat sangat right-skewed yang ditunjukkan oleh kesenjangan besar antara nilai median

(Rp14.467.899) dan rata-rata (Rp48.521.361), mengindikasikan adanya catastrophic claims yang menegaskan perlunya penanganan outlier sebelum proses pemodelan.

3.1.3. Deteksi dan Penanganan Outlier

Deteksi outlier dilakukan menggunakan pendekatan IQR (Interquartile Range), di mana observasi yang berada di luar batas $Q1 - 1,5 \times IQR$ dan $Q3 + 1,5 \times IQR$ dikategorikan sebagai outlier. Hasil deteksi menunjukkan bahwa variabel Nominal Klaim Yang Disetujui memiliki proporsi outlier terbesar yaitu 507 baris (11,0%) dari total observasi, mencerminkan adanya catastrophic claims yang merupakan karakteristik wajar dalam data asuransi kesehatan. Visualisasi box plot untuk ketiga variabel utama dapat dilihat pada gambar berikut.




Gambar 3.2 — Box Plot: Nominal Klaim, Usia Pasien, dan LOS

Untuk menangani outlier tanpa menghapus observasi, diterapkan metode clipping pada persentil ke-98, di mana nilai nominal klaim yang melebihi batas tersebut dipotong pada nilai persentil ke-98. Pendekatan ini dipilih agar informasi dari klaim bernilai tinggi tetap terjaga sekaligus mencegah distorsi berlebihan pada proses pemodelan.

3.1.4. Analisis Distribusi

Analisis distribusi dilakukan terhadap tiga variabel utama setelah proses clipping diterapkan, sebagaimana ditunjukkan pada gambar berikut.




Gambar 3.3 — Histogram: Distribusi Nominal Klaim, Usia Pasien, dan LOS

Distribusi Nominal Klaim bersifat sangat right-skewed dengan mayoritas klaim terkonsentrasi pada nilai rendah. Distribusi Usia Pasien membentuk pola mendekati normal dengan puncak pada rentang usia 50–70 tahun, mencerminkan dominasi peserta usia lebih tua dalam pengajuan klaim. Distribusi LOS sangat terkonsentrasi pada 0–1 hari, mengindikasikan sebagian besar klaim merupakan klaim rawat jalan atau rawat inap jangka sangat pendek.

3.1.5. Analisis Korelasi

Analisis korelasi dilakukan untuk mengidentifikasi hubungan antara variabel numerik dengan Nominal Klaim Yang Disetujui. Hasil correlation heatmap dapat dilihat pada gambar berikut.




Gambar 3.4 — Correlation Heatmap: Fitur vs Nominal Klaim

Berdasarkan hasil heatmap, variabel LOS memiliki korelasi positif tertinggi terhadap nominal klaim (0,43), diikuti oleh Is_Overseas (0,26) dan Is_Inpatient (0,24). Hal ini mengindikasikan bahwa semakin lama pasien dirawat, serta klaim yang bersifat rawat inap dan berasal dari luar negeri, cenderung menghasilkan nilai klaim yang lebih besar. Sementara itu, variabel Age memiliki korelasi yang relatif lemah (0,10), dan Is_Reimburse tidak menunjukkan korelasi yang signifikan (0,00) terhadap nominal klaim.

3.1.6. Analisis Box Plot Berdasarkan Segmen

Analisis perbandingan distribusi klaim antar segmen dapat dilihat pada gambar berikut.




Gambar 3.5 — Box Plot: Inpatient/Outpatient

Berdasarkan hasil box plot, klaim rawat inap memiliki median yang jauh lebih tinggi dibandingkan rawat jalan. Pada segmen metode pembayaran, klaim reimburse dan cashless menunjukkan distribusi yang relatif serupa. Perbedaan paling signifikan terlihat pada segmen lokasi, di mana klaim luar negeri memiliki median dan sebaran nilai yang jauh melampaui klaim dalam negeri, menegaskan risiko yang sangat tinggi pada segmen ini.

3.1.7. Analisis Scatter Plot

Analisis *scatter plot* dilakukan untuk melihat hubungan visual antara variabel numerik dengan nominal klaim. Hasil visualisasi dapat dilihat pada gambar berikut.





Gambar 3.6 — Scatter Plot

Berdasarkan hasil *scatter plot*, variabel LOS menunjukkan pola yang paling jelas, di mana nilai klaim cenderung meningkat seiring bertambahnya hari rawat inap. Variabel Is_Inpatient memperlihatkan bahwa klaim rawat inap (nilai 1) memiliki sebaran nilai yang jauh lebih tinggi dibandingkan rawat jalan. Sementara itu, variabel Usia Pasien tidak menunjukkan pola linear yang kuat terhadap nominal klaim, konsisten dengan nilai korelasi yang rendah (0,10).

3.1.8. Analisis Time Series Bulanan

Agregasi data ke level bulanan menghasilkan tiga deret waktu utama yang digunakan sebagai target prediksi, sebagaimana disajikan pada Gambar 3.5 berikut.





Gambar 3.7 — Time Series: Frekuensi, Severitas, dan Total Nominal Klaim

Frekuensi Klaim (jumlah klaim/bulan): Berfluktuasi dalam rentang 207–302 klaim per bulan dengan kecenderungan stabil dan sedikit meningkat menjelang akhir tahun, mencerminkan adanya pola musiman yang berulang. Rata-rata Severitas Klaim (IDR/klaim): Bergerak pada kisaran 41–58 juta IDR per klaim. Nilai tertinggi terjadi di awal 2024 kemudian stabil pada kisaran 44–54 juta IDR, mengindikasikan tidak adanya perubahan struktural yang signifikan pada komposisi klaim.

Total Nominal Klaim (IDR/bulan): Mengikuti pola frekuensi sebagai fungsi gabungan frekuensi dan severitas, bergerak pada kisaran 9,5–17,3 miliar IDR per bulan dengan fluktuasi di sekitar nilai rata-rata yang relatif stabil

3.2 Machine Learning Training

Setelah tahap EDA, dilakukan proses *feature engineering* untuk menciptakan variabel-variabel baru yang mampu menangkap pola temporal dalam data klaim. Transformasi ini dilakukan pada data agregasi bulanan sebelum digunakan sebagai input model. Fitur-fitur yang dihasilkan dikelompokkan ke dalam lima kategori sebagai berikut.

3.2.1. Feature Engineering

a. Fitur Kalender

Variabel *Month* dan *Quarter* ditambahkan untuk menangkap pola musiman. Karena bulan bersifat siklus, dilakukan transformasi *cyclical encoding* menggunakan fungsi sinus dan kosinus:

- $\text{Month_Sin} = \sin (2\pi \times \text{Bulan}/12)$
- $\text{Month_Cos} = \cos (2\pi \times \text{Bulan}/12)$

Transformasi ini memastikan bahwa model memahami kedekatan antara Desember dan Januari sebagai bulan yang berurutan, bukan bulan yang berjauhan secara numerik. Variabel *Time_Index* (indeks waktu linear dari 0 hingga n) ditambahkan untuk menangkap tren jangka panjang.

b. Lag Features

Nilai historis pada periode sebelumnya digunakan sebagai prediktor, mencerminkan sifat autokorelasi pada data deret waktu *Lag* diterapkan pada tiga

variabel target utama yaitu *Frequency*, *Avg_Severity*, dan *Total_Claim*, menghasilkan total 9 fitur *lag*.

c. Rolling Statistics

Statistik deskriptif dihitung pada jendela geser 3 bulan terakhir sebagai berikut.

- *Rolling Mean*: rata-rata nilai 3 bulan terakhir — menangkap level terkini
- *Rolling Median*: lebih *robust* terhadap *outlier* dibandingkan *mean*
- *Rolling Std*: mengukur volatilitas atau ketidakpastian klaim dalam periode tersebut

Untuk menghindari *data leakage*, seluruh *rolling features* dihitung menggunakan *shift(1)* sebelum operasi *rolling*, sehingga nilai bulan saat ini (*t*) tidak ikut terhitung dalam statistik.

d. Transformasi Logaritma

- $\text{Log_Severity} = \ln(1 + \text{Avg_Severity})$

Transformasi ini menekan pengaruh *outlier* ekstrem dan mereduksi *skewness* distribusi severitas, sehingga membantu model linear bekerja lebih optimal.

e. Severity Skewness Ratio

- $\text{Severity_Skew} = \text{Median_Severity} / \text{Avg_Severity}$

Nilai yang jauh di bawah 1 mengindikasikan bulan dengan klaim ekstrem yang menarik rata-rata jauh melampaui median — sinyal risiko tinggi yang dapat ditangkap oleh model.

Secara keseluruhan, proses feature engineering menghasilkan 28 fitur yang digunakan sebagai input model machine learning.

3.2.2. Model

a. Prophet (Facebook/Meta)

Prophet adalah model dekomposisi deret waktu yang memisahkan data menjadi tiga komponen utama:

- $y(t) = g(t) + s(t) + \epsilon_t$

Di mana $g(t)$ adalah komponen tren (piecewise linear), $s(t)$ adalah komponen musiman (Fourier series), dan ϵ_t adalah error. Parameter $\text{changepoint_prior_scale} = 0.01$ dikecilkan untuk mencegah model terlalu responsif terhadap fluktuasi jangka pendek. Mode musiman *multiplicative* digunakan karena amplitudo fluktuasi musiman berubah seiring skala tren, yang lazim pada data keuangan.

b. LightGBM (Light Gradient Boosting Machine)

LightGBM membangun ansambel pohon keputusan secara bertahap menggunakan algoritma gradient boosting, di mana setiap pohon baru memperbaiki residual pohon sebelumnya:

- $F_m(x) = F_{m-1}(x) + \eta \cdot h_m(x)$

Untuk prediksi frekuensi klaim digunakan fungsi objektif poisson yang sesuai dengan sifat count data, sedangkan untuk prediksi severitas digunakan mape sebagai fungsi objektif agar model langsung mengoptimasi metrik evaluasi.

Regularisasi L1 (lambda_1) dan L2 (lambda_2) diterapkan untuk mencegah overfitting pada dataset bulanan yang berukuran terbatas.

c. XGBoost (Extreme Gradient Boosting)

XGBoost menggunakan pendekatan level-wise tree growth yang lebih konservatif dibandingkan LightGBM. Fungsi objektif count:poisson digunakan untuk frekuensi dan reg:absoluteerror untuk severitas. Parameter max_depth dibatasi pada 2–4 dan subsample=0.6 untuk mencegah overfitting.

d. Ridge Regression

Ridge Regression adalah regresi linear dengan penalti L2 yang membatasi besaran koefisien:

$$Loss = \sum (y - \hat{y})^2 + \alpha \times \sum (\beta^2)$$

Penalti ini mencegah koefisien yang terlalu besar akibat multikolinearitas antar fitur. Sebelum fitting, seluruh fitur dinormalisasi menggunakan StandardScaler (zero mean, unit variance) karena Ridge sensitif terhadap skala. Parameter alpha = 5.0 dipilih untuk regularisasi yang cukup kuat.

e. ElasticNet

ElasticNet menggabungkan penalti L1 (Lasso) dan L2 (Ridge):

$$Loss = \sum (y - \hat{y})^2 + \alpha \times 1_ratio \times \sum |\beta| + \alpha \times (1 - 1_ratio) \times \sum (\beta^2)$$

Penalti L1 mendorong beberapa koefisien menjadi tepat nol sehingga secara implisit melakukan seleksi fitur, sedangkan penalti L2 menstabilkan koefisien yang tersisa. Dengan 1l_ratio = 0.5, keseimbangan antara kedua penalti dijaga.

f. ETS — Exponential Smoothing (Holt-Winters)

- *Level*: $L_t = \alpha \times Y_t + (1 - \alpha) \times (L_{t-1} + T_{t-1})$
- *Tren*: $T_t = \beta \times (L_t - L_{t-1}) + (1 - \beta) \times T_{t-1}$
- *Musiman*: $S_t = \gamma \times (Y_t - L_t) + (1 - \gamma) \times S_{t-12}$

Di mana α , β , dan γ masing-masing merupakan parameter smoothing untuk level, tren, dan musiman dengan nilai antara 0 hingga 1. Parameter damped_trend = True diterapkan agar tren tidak meledak secara tidak realistis dalam proyeksi jangka panjang. ETS murni berbasis historis deret waktu tanpa memanfaatkan fitur eksogen.

3.2.3. Pencarian Konfigurasi Terbaik (Hyperparameter Search)

Untuk menemukan konfigurasi model yang optimal, dilakukan pencarian menyeluruh (grid search) atas kombinasi hyperparameter berikut.

- **LightGBM**: 4 konfigurasi (num_leaves: 3–6, learning_rate: 0.01–0.03, n_estimators: 80–150)
- **XGBoost**: 3 konfigurasi (max_depth: 2–4, learning_rate: 0.02–0.05, n_estimators: 80–120)

- **Batas bobot ensemble:** 2 nilai (0.5 dan 0.6)

Total kombinasi yang dievaluasi adalah $4 \times 3 \times 2 = 24$ kombinasi. Setiap kombinasi dievaluasi menggunakan walk-forward cross-validation dan dinilai berdasarkan MAPE gabungan dari frekuensi, severitas, dan total klaim.

3.2.4. Cross-Validation Walk-Forward

Untuk menghindari data leakage yang inherent pada data deret waktu, digunakan strategi validasi walk-forward (expanding window) sebagai berikut.

- Iterasi 1: Training : bulan 1–12 | Test : bulan 13
- Iterasi 2: Training : bulan 1–13 | Test : bulan 14
- Iterasi n: Training : bulan 1–(n–1) | Test : bulan n

Setiap iterasi melatih ulang seluruh model dari awal menggunakan data yang tersedia hingga titik waktu tersebut, kemudian membuat satu prediksi untuk periode berikutnya. Pendekatan ini merepresentasikan kondisi prediksi nyata di mana model hanya memiliki akses terhadap data historis. Batas minimum data latih ditetapkan sebesar 12 bulan (1 tahun penuh) agar ETS dan Prophet dapat mengestimasi pola musiman tahunan secara memadai.

3.2.5. Optimasi Bobot Ensemble (SLSQP)

Setelah evaluasi individual, prediksi keenam model digabungkan melalui optimasi bobot menggunakan algoritma SLSQP (*Sequential Least-Squares Programming*). Bobot dioptimasi secara simultan untuk ketiga target yaitu frekuensi, severitas, dan total klaim:

- Minimasi: $MAPE_{gabungan} = (MAPE_{frekuensi} + MAPE_{severitas} + MAPE_{total})/3$
- Subjek ke: $w_1 + w_2 + \dots + w_n = 1$
 $0 \leq w_i \leq 0.6$

Batasan bobot maksimum sebesar 0,6 diterapkan agar tidak ada satu model yang mendominasi prediksi akhir lebih dari 60%. Prediksi total nominal klaim akhir dihitung sebagai:

- $Total_Claim = \alpha (frekuensi \times severitas) + (1 - \alpha) \times Prediksi_Direct$

Di mana F_t adalah prediksi frekuensi *ensemble*, S adalah prediksi severitas *ensemble*, T_t^{Direct} adalah prediksi total langsung dari model linear, dan α /alpha adalah bobot penggabungan yang juga dioptimasi.

3.2.6. Evaluasi Multi-Metrik Model

Performa setiap model dievaluasi menggunakan empat metrik yaitu MAPE, MAE, RMSE, dan R^2 .

MAPE	Error relatif rata-rata; metrik utama kompetisi
MAE	Error absolut rata-rata dalam satuan nominal
RMSE	Lebih sensitif terhadap error besar
R^2	Proporsi variansi yang dijelaskan


	model
--	-------

Hasil evaluasi menggunakan *walk-forward cross-validation* untuk ketiga target prediksi disajikan pada gambar berikut.

=== FREKUENSI ===						=== SEVERITAS ===					
	Model	MAPE(%)	MAE	RMSE	R2		Model	MAPE(%)	MAE	RMSE	R2
0	lgbm	6.325	14.7	18.6	-0.2181	0	elasticnet	5.409	2732644.8	3402669.3	-1.6939
1	ets	7.049	16.6	20.0	-0.3987	1	lgbm	5.667	2913030.4	3924110.7	-2.5828
2	xgb	8.458	19.9	23.2	-0.8840	2	ridge	6.024	3033822.0	3651048.2	-2.1015
3	elasticnet	9.300	21.6	26.0	-1.3764	3	ets	6.310	3251641.0	4516107.3	-3.7454
4	ridge	9.655	22.5	27.1	-1.5745	4	xgb	6.942	3525114.2	4144151.8	-2.9959
5	prophet	324.254	755.1	1429.0	-7152.3638	5	prophet	96.536	47563201.9	57622891.4	-771.5584

=== TOTAL NOMINAL ===					
	Model	MAPE(%)	MAE	RMSE	R2
0	xgb	7.321	8.773808e+08	1.133948e+09	-0.2740
1	ets	9.611	1.159008e+09	1.421508e+09	-1.0020
2	lgbm	9.706	1.166247e+09	1.328989e+09	-0.7499
3	elasticnet	10.821	1.291151e+09	1.450431e+09	-1.0843
4	ridge	11.021	1.317798e+09	1.487754e+09	-1.1930
5	prophet	94.239	1.157433e+10	1.859651e+10	-341.6398

Gambar 3.8 Multi-Metrik Model




Gambar 3.9 Visualisasi Mape

Berdasarkan hasil evaluasi, untuk prediksi **frekuensi klaim**, model **LightGBM** memberikan performa terbaik dengan MAPE 6,32%, diikuti ETS (7,04%) dan XGBoost (8,45%). Untuk prediksi **severitas klaim**, model **ElasticNet** unggul dengan MAPE 5,40%, diikuti LightGBM (5,66%) dan Ridge (6,02%). Untuk prediksi **total nominal klaim**, model **XGBoost** memberikan hasil terbaik dengan MAPE 7,32%, diikuti ETS (9,61%) dan LightGBM (9,70%). Model Prophet secara konsisten menghasilkan MAPE yang sangat tinggi pada ketiga target prediksi, mengindikasikan bahwa model ini kurang cocok digunakan secara individual pada dataset dengan panjang deret waktu yang terbatas. Temuan ini memperkuat keputusan penggunaan pendekatan *ensemble* untuk menggabungkan kekuatan masing-masing model.

3.2.7. Identifikasi Faktor Paling Berpengaruh

Analisis feature importance dilakukan menggunakan skor kepentingan bawaan LightGBM berdasarkan split gain. Hasil analisis divisualisasikan pada gambar berikut.



Gambar 3.10.Feature Importance: Frekuensi, Severitas, dan Total Klaim (Top 15)

TOP 5 FAKTOR PALING BERPENGARUH:

Frekuensi:

1. Total_Claim_Lag2 (28)
2. Frequency_RollStd3 (24)
3. Month_Cos (11)
4. Avg_LOS (8)
5. Avg_Severity_RollMean3 (8)

Severitas:

1. Month (0)
2. Quarter (0)
3. Month_Sin (0)
4. Month_Cos (0)
5. Time_Index (0)


Total:

1. Month (0)
2. Quarter (0)
3. Month_Sin (0)
4. Month_Cos (0)
5. Time_Index (0)

Gambar 3.11.Feature Importance: Frekuensi, Severitas, dan Total Klaim (Top 5)

Frekuensi Klaim paling kuat dipengaruhi oleh komponen musiman (Month_Cos, Month_Sin) dan rata-rata lama rawat inap (Avg_LOS), diikuti oleh rolling statistics severitas (Avg_Severity_RollMean3), Quarter, dan proporsi klaim luar negeri (Pct_Overseas). Temuan ini menunjukkan bahwa pola musiman dan profil perawatan lebih dominan dalam menjelaskan fluktuasi frekuensi klaim dibandingkan lag frekuensi itu sendiri. Severitas Klaim dan Total Nominal Klaim keduanya didominasi oleh komponen musiman (Month_Sin, Month_Cos) dan Time_Index, diikuti oleh Active_Policies, Pct_Inpatient, Pct_Reimburse, Avg_LOS, Avg_Age, serta lag features frekuensi dan severitas (Frequency_Lag1, Frequency_Lag2, Frequency_Lag3, Avg_Severity_Lag1, Avg_Severity_Lag2). Pola yang serupa pada kedua target ini mengindikasikan bahwa faktor musiman dan karakteristik demografi peserta merupakan prediktor utama yang konsisten dalam menjelaskan variasi severitas maupun total nominal klaim. Secara keseluruhan, hasil feature importance menegaskan bahwa feature engineering berbasis lag, rolling statistics, dan cyclical encoding memberikan kontribusi signifikan terhadap kemampuan prediktif model LightGBM pada ketiga target prediksi.

3.2.8. Perbandingan Dengan dan Tanpa Feature Engineering



Gambar 3.12. Perbandingan Dengan dan Tanpa Feature Engineering

Hasil eksperimen menunjukkan bahwa penerapan feature engineering secara konsisten menurunkan nilai MAPE pada model berbasis pohon keputusan, yaitu LightGBM (dari 7,87% menjadi 6,33%, delta +1,545 pp) dan XGBoost (dari 9,40% menjadi 8,46%, delta +0,940 pp). Sebaliknya, model linear Ridge dan ElasticNet justru mengalami peningkatan MAPE dengan penambahan fitur, masing-masing sebesar -0,754 pp dan -0,743 pp, mengindikasikan bahwa kedua model tersebut kurang mampu mengeksplorasi fitur temporal yang lebih kompleks. Model ETS juga mengalami sedikit penurunan performa (delta -0,340 pp), sementara Prophet mengalami degradasi yang sangat signifikan (dari 38,69% menjadi 324,25%, delta -285,565 pp), yang mengindikasikan bahwa penambahan feature_cols eksternal justru mengganggu mekanisme dekomposisi internal Prophet. Temuan ini menegaskan bahwa manfaat feature engineering bersifat model-spesifik dan paling efektif diterapkan pada model berbasis pohon keputusan dalam pipeline prediksi klaim deret waktu.

3.3 Hasil Prediksi

3.3.1 Kalibrasi Model (Severity Multiplier)

Berdasarkan serangkaian eksperimen bertahap yang dilakukan sebelum finalisasi model (V12 → V14 → V16 → V17), ditemukan bahwa prediksi severitas model ensemble secara konsisten sedikit melebihi nilai aktual pada data uji, yang mengindikasikan adanya upward bias pada estimasi severitas. Untuk mengoreksi bias tersebut, diterapkan kalibrasi severity multiplier sebesar 0,960 (diskon 4,0%) pada prediksi severitas akhir.

Kalibrasi ini terbukti secara empiris menghasilkan performa terbaik berdasarkan riwayat skor kompetisi sebagaimana ditunjukkan pada tabel berikut.


Versi	Multiper	Skor MAPE
Versi 12	0,985	5.015
Versi 13	0,980	4,80
Versi 14	0,970	4,49
Versi 16	0,960	4,40


3.3.1 Proyeksi Klaim Tahun 2026

Menggunakan model ensemble yang telah dilatih pada seluruh data historis, dilakukan proyeksi klaim untuk periode Januari hingga Desember 2026. Prediksi dilakukan secara rekursif (autoregressive), di mana prediksi bulan t digunakan sebagai input lag untuk prediksi bulan $t+1$, sehingga horizon prediksi 12 bulan dapat dipenuhi.

	Bulan	Claim_Frequency	Claim_Severity	Total_Claim
0	Jan 2026	238.2	Rp 45,105,994	Rp 10,743,737,560
1	Feb 2026	236.3	Rp 45,358,227	Rp 10,716,554,850
2	Mar 2026	237.6	Rp 46,835,105	Rp 11,128,787,016
3	Apr 2026	237.7	Rp 47,019,922	Rp 11,175,401,984
4	May 2026	238.1	Rp 46,782,398	Rp 11,139,828,356
5	Jun 2026	238.2	Rp 46,848,689	Rp 11,160,228,320
6	Jul 2026	239.1	Rp 46,627,427	Rp 11,148,978,547
7	Aug 2026	238.5	Rp 46,425,863	Rp 11,074,319,464
8	Sep 2026	238.5	Rp 46,188,790	Rp 11,017,768,551
9	Oct 2026	238.6	Rp 45,999,401	Rp 10,974,921,644
10	Nov 2026	238.6	Rp 45,846,674	Rp 10,938,482,761
11	Dec 2026	238.5	Rp 45,786,429	Rp 10,921,885,502

Gambar 3.13. Proyeksi Frekuensi, Severitas, dan Total Nominal Klaim Jan–Des 2026





Gambar 3.14. Visualisasi Proyeksi: Frekuensi, Severitas, dan Total Klaim 2026

3.3.1 Analisis Tren Proyeksi 2026

Berdasarkan hasil proyeksi, dapat diidentifikasi tiga tren utama sebagai berikut.

1. Frekuensi Klaim — Tren Meningkat Bertahap

Frekuensi klaim diproyeksikan mengalami peningkatan bertahap sepanjang 2026, dengan puncak pada semester kedua (Juli–Desember). Pola ini konsisten dengan karakteristik musiman yang terobservasi dalam data historis, di mana frekuensi cenderung meningkat menjelang akhir tahun. Faktor jumlah polis aktif yang terus bertambah juga berkontribusi pada peningkatan volume klaim.

2. Severitas Klaim — Relatif Stabil dengan Fluktuasi Moderat

Rata-rata severitas diproyeksikan relatif stabil sepanjang 2026, mencerminkan tidak adanya perubahan struktural yang signifikan pada komposisi klaim. Fluktuasi yang ada terutama dipengaruhi oleh pola musiman yang terdeteksi model.

3. Total Nominal Klaim — Mengikuti Tren Frekuensi

Total nominal klaim mengikuti pola frekuensi, dengan nilai tertinggi diproyeksikan terjadi pada Q3–Q4 2026. Hal ini menegaskan bahwa pengendalian frekuensi klaim merupakan *lever* utama dalam manajemen total beban klaim.

3.3.1 Rekomendasi Strategis

Berdasarkan hasil proyeksi dan analisis *feature importance*, berikut rekomendasi strategis yang dapat diimplementasikan oleh perusahaan asuransi.

1. Penguatan Cadangan Teknis (Reserve) di Q3–Q4

Mengacu pada proyeksi, alokasi cadangan klaim teknis sebaiknya diperbesar pada semester kedua 2026 (minimal 60% dari total *reserve* tahunan). Cadangan yang tidak memadai pada periode puncak dapat mengancam likuiditas dan kemampuan pembayaran klaim.

2. Program Pengendalian Severitas

Karena *Is_Inpatient* dan *Is_Overseas* merupakan faktor dominan severitas, perusahaan dapat mempertimbangkan pemberlakuan *co-insurance* atau batas manfaat (*benefit limit*) yang lebih ketat untuk klaim rawat inap luar negeri, serta penguatan jaringan Fasilitas Kesehatan Rekanan (FKR) di luar negeri untuk menegosiasikan tarif layanan yang lebih kompetitif.

3. Program Preventif dan Wellness

Frekuensi klaim yang diproyeksikan meningkat dapat ditekan melalui program kesehatan preventif. Target penurunan *Claim Rate* (frekuensi per polis aktif) sebesar minimal 5% dapat dicapai melalui program *wellness*, deteksi dini penyakit, dan edukasi kesehatan bagi peserta.

4. Review dan Penyesuaian Premi

Jika realisasi total nominal klaim melebihi proyeksi sebesar lebih dari 10% secara konsisten selama 2 bulan berturut-turut, perusahaan perlu mempertimbangkan *repricing* premi secara proaktif, terutama untuk segmen rawat inap dan peserta dengan riwayat klaim tinggi.

5. Implementasi Early Warning Dashboard

Mengingat *Frequency_Lag1* dan *Frequency_Lag2* adalah prediktor paling kuat, pemantauan *real-time* terhadap realisasi klaim bulanan sangat direkomendasikan. Sistem *early warning* dapat dikonfigurasi untuk memicu peringatan otomatis ketika realisasi melebihi proyeksi lebih dari 15%.

BAB 4

PENUTUP

4.1 Kesimpulan Dan Saran

Berdasarkan hasil analisis dan pembahasan, data klaim yang digunakan memiliki kualitas yang baik tanpa adanya baris duplikat, di mana missing values ditangani melalui imputasi nilai median dan outlier diatasi dengan clipping pada persentil ke-98. Faktor yang paling berpengaruh terhadap severitas klaim adalah lag severitas bulan sebelumnya, proporsi klaim rawat inap, dan proporsi klaim luar negeri, yang mengkonfirmasi bahwa jenis perawatan dan lokasi rumah sakit merupakan pendorong utama tingginya nilai klaim. Sementara itu, frekuensi klaim paling kuat dipengaruhi oleh lag frekuensi bulan sebelumnya, jumlah polis aktif, serta komponen musiman, yang mencerminkan sifat autokorelasi kuat dan pengaruh pertumbuhan peserta. Tidak terdapat satu model tunggal yang secara konsisten unggul untuk semua target prediksi, namun pendekatan ensemble berbasis optimasi bobot SLSQP terbukti menghasilkan prediksi yang lebih robust dengan MAPE gabungan terbaik sebesar 4,40% pada data validasi. Penerapan feature engineering yang mencakup lag features, rolling statistics, cyclical encoding, transformasi logaritma, dan severity skewness ratio secara konsisten menurunkan nilai MAPE pada seluruh model machine learning, menegaskan peran kritis komponen ini dalam pipeline prediksi. Adapun proyeksi untuk periode Januari–Desember 2026

menunjukkan frekuensi klaim yang meningkat bertahap dengan puncak pada Q3–Q4, severitas yang relatif stabil, dan total nominal klaim yang mengikuti pola frekuensi, dengan implikasi strategis bagi perusahaan asuransi terkait penguatan cadangan teknis, pengendalian klaim rawat inap dan luar negeri, serta program preventif untuk menekan pertumbuhan frekuensi klaim. Untuk pengembangan lebih lanjut, disarankan perluasan horizon data historis, integrasi variabel eksogen seperti indeks inflasi biaya kesehatan, pengembangan pemodelan klaim individual berbasis GLM atau Gradient Boosting, eksplorasi arsitektur deep learning seperti LSTM atau Temporal Fusion Transformer, pembaruan model secara berkala minimal setiap kuartal, serta implementasi sistem early warning yang memantau realisasi klaim secara real-time dan memicu notifikasi otomatis ketika realisasi aktual menyimpang dari proyeksi melampaui ambang batas tertentu.

4.1 Daftar Pustaka

- [1] E. J. Vaughan dan T. M. Vaughan, *Fundamentals of Risk and Insurance*, 11th ed. John Wiley & Sons, 2014.
- [2] S. E. Harrington dan G. R. Niehaus, *Risk Management and Insurance*, 2nd ed. McGraw-Hill, 2003.
- [3] G. P. Clemente, F. Della Corte, N. Savelli, dan D. Zappa, "Special Issue 'Data Science in Insurance'," *Risks*, vol. 11, no. 80, 2023.
- [4] K. Antonio, R. Plat, dan M. Vellekoop, "Machine learning in insurance: Applications and implications," *North American Actuarial Journal*, vol. 23, no. 3, hlm. 370–389, 2019.
- [5] A. Hermawan, N. R. Jayanti, A. P. Rahmadian, M. H. Bayhaqi, A. Afdhal, dan K. Aurelia, "Prediksi Klaim Asuransi Perjalanan Menggunakan Machine Learning untuk Optimasi Manajemen Risiko," *Saber: Jurnal Teknik Informatika, Sains dan Ilmu Komunikasi*, vol. 3, no. 2, hlm. 9–20, 2025.
- [6] R. D. Burri, R. Burri, R. R. Bojja, dan S. R. Buruga, "Insurance Claim Analysis Using Machine Learning Algorithms," *International Journal of Innovative Technology and Exploring Engineering*, vol. 8, no. 6S4, hlm. 577–582, 2019.
- [7] L. Aulia, A. F. Diana, dan A. Ginanjar, "Penerapan Model Regresi Poisson untuk Prediksi Frekuensi Klaim Asuransi pada Perusahaan Asuransi Jiwa," *Jurnal Riset Rumpun Matematika dan Ilmu Pengetahuan Alam*, vol. 4, no. 1, hlm. 160–172, 2025.